

IDMSpHGiAGR

Identyfikacja DMS pomiędzy HG i AGR

Grupa 4

2026-06-24

Table of contents

1 IDMSpHGiAGR - Identyfikacja DMS pomiędzy HG i AGR	1
1.1 Wstęp	1
1.1.1 Abstrakt / streszczenie	1
1.1.2 Cel naukowy	2
1.1.3 Aktualny stan wiedzy	2
1.2 Metodologia	5
1.2.1 Kohorty i liczba próbek	5
1.2.2 Mapy metylacyjne	5
1.2.3 Analiza DMS	5
1.2.4 Metoda statystyczna do porównywania populacji.	8
1.3 Oczekiwane wyniki	9
1.3.1 Cechy charakterystyczne	9
1.3.2 Wpływ na tezy historyczne	10
1.3.3 Możliwe problemy	10

1 IDMSpHGiAGR - Identyfikacja DMS pomiędzy HG i AGR

1.1 Wstęp

1.1.1 Abstrakt / streszczenie

Projekt IDMSpHGiAGR ma na celu opracowanie nowej, niezależnej od artefaktów archeologicznych metody klasyfikacji prehistorycznych strategii utrzymania (łowców-zbieraczy [HG] vs. społeczności rolniczych [AGR]) na podstawie analizy porównawczej map metylacji DNA.

Do zdefiniowania referencyjnych sygnatur epigenetycznych wykorzystamy metodologię użytą w badaniu [1]. W oparciu o ten model wyodrębniamy trzy abstrakcyjne klasy populacyjne:

- grupę agrarną osiadłą,
- grupę agrarną niedawno poddaną transformacji środowiskowej,
- tradycyjną grupę łowiecko-zbieracką

Zastosowanie analizy *cis-meQTL* umożliwi nam odseparowanie adaptacji środowiskowej od tej determinowanej przez uwarunkowania genetyczne. Jest to kluczowe do uzyskania informacji o modyfikacjach związanych ze zmianami środowiskowymi.

Uzyskane sygnatury zostaną zwalidowane na populacjach antycznych o jednoznacznych strategiach utrzymania, to jest: głębokim neolitycznym tle (dawniej niż 20 tys. lat p.n.e. – pewne HG) oraz utrwalonych społecznościach rolniczych (do 2 tys. lat p.n.e. – pewne AGR).

Pozycje różnicowo zmetylowane (DMS), wykazujące istotną statystycznie zależność ze zbiorami walidacyjnymi, zostaną zdefiniowane jako zestaw stabilnych ewolucyjnie markerów epigenetycznych (#TODO - jakiś skrót tego).

Mając już zestaw stabilnych ewolucyjnie markerów, użyjemy dedykowanego modelu probabilistycznego do zbadanych profili genetycznych w celu otrzymania danych, które dadzą nam nową perspektywę na sposób funkcjonowania populacji mezolitycznych, takich jak Çatalhöyük.

1.1.2 Cel naukowy

Celem naukowym jest skonstruowanie nowej metody epigenetycznej umożliwiającej klasyfikację populacji prehistorycznych jako *hunter-gatherers* (HG) lub rolniczo-miejskich (AGR), niezależnej od artefaktów archeologicznych.

Metoda wykorzystywałaby scharakteryzowane modyfikacje epigenetyczne we współczesnych populacjach autochtonicznych HG i AGR zestawionych z ludnościami antycznymi.

1.1.3 Aktualny stan wiedzy

1.1.3.1 Metody rekonstrukcji map metylacji

1.1.3.1.1 Wykorzystane zjawisko - deaminacja cytozyn

Rekonstrukcja map metylacji z kopalnego DNA (aDNA) opiera się na zjawisku deaminacji cytozyn – dominującym procesie chemicznego rozkładu aDNA [2]. Niemetylowana cytozyna deaminuje do uracylu ($C \rightarrow U$), natomiast metylowana 5-metylocytozyna deaminuje do tyminy ($5mC \rightarrow T$). Tempo deaminacji jest silnie zależne od struktury fragmentu: w jednoniciowych cząsteczkach na końcach fragmentów sięga kilkudziesięciu procent, podczas gdy w częściach dwuniciowych wynosi około 1% lub mniej; uśredniony wskaźnik deaminacji fragmentu mieści się zwykle w przedziale 1–3%. Protokoły przygotowania bibliotek z (częściowym lub pełnym) traktowaniem USER / UDG (*Uracil-Specific Excision Reagent*) usuwają uracyl,

ale nie naruszają tymin. Dzięki temu udział tymin na wyspach CpG (gdzie cytozyna jest metylowana w genomie ssaków), zwany wskaźnikiem $C \rightarrow T$, może służyć jako estymator przedśmiertnego poziomu metylacji.

Dla pozycji i definiuje się wskaźnik:

$$C \rightarrow T(i) = \frac{t_i}{t_i + c_i}$$

Gdzie t_i oraz c_i to liczby odczytów z tyminą i cytozyną na danej pozycji. Wyższy wskaźnik odpowiada wyższemu poziomowi metylacji. Ponieważ poziomy metylacji sąsiadujących CpG są silnie skorelowane (kometylacja w obrębie regionów rzędu ≈ 2 kpz), estymację wygładza się w przesuwym oknie obejmującym kilka–kilkadziesiąt kolejnych CpG, co radykalnie redukuje błąd standardowy estymatora.

1.1.3.1.2 Metoda oryginalna

Metoda oryginalna [3] dotyczyła pierwszej pełnej rekonstrukcji metylomu neandertalczyka i denisowianina. Wymaga próbek o wysokim pokryciu shotgun ($\geq 15\times$) poddanych traktowaniu USER. Porównanie z metylomami współczesnych ludzi pozwoliło zidentyfikować ≈ 2000 regionów różnicowo zmetylowanych (DMR), w tym istotne zmiany w klastrze *HOXD*, potencjalnie tłumaczące różnice anatomiczne między człowiekiem archaicznym a współczesnym. Ograniczeniem jest jednak dostępność danych: bardzo niewiele próbek aDNA spełnia jednocześnie oba wymagania — wystarczająco wysokie pokrycie oraz przygotowanie biblioteki z traktowaniem USER. W praktyce metodę zastosowano dotąd jedynie do nielicznych okazów (neandertalczyk, denisowianin oraz kilku anatomicznie współczesnych ludzi). ***

1.1.3.1.3 Adaptacja metody do danych o niskim pokryciu (Barouch i in., 2024, NAR)

Zdecydowana większość kopalnych osobników jest sekwencjonowana metodą hybrydizacyjnego wzbogacania (*in-solution capture*), najczęściej z użyciem panelu 1240K ($\approx 1,24$ mln SNP) – sekwencjonowanie tylko niewielkich fragmentów genomu, co daje dane zbyt płytkie do rekonstrukcji metylacji na poziomie pojedynczego osobnika. Autorzy [4] wykorzystują obserwację, że zmienność metylacji wewnątrz populacji jest mniejsza niż między populacjami – populacje mają więc charakterystyczne profile metylacyjne. Zamiast rekonstruować mapę indywidualną, łączą odczyty wielu osobników z tej samej populacji, uzyskując mapę metylacji reprezentatywną dla całej populacji. Kluczowe elementy procedury:

- **Naiwne łączenie (naive pulling)** – proste sumowanie liczników C i T w każdej pozycji CpG ze wszystkich osobników; działa równie dobrze lub lepiej niż wariant „zaawansowany” uwzględniający indywidualne tempa deaminacji (osobnicy z tego samego miejsca i okresu przeszli zbliżone procesy deaminacji).
- **Filtrowanie** – usunięcie domniemanych duplikatów PCR oraz pozycji CpG o wskaźniku $C \rightarrow T > 0,25$ (prawdopodobnie mutacje, a nie deaminacja).

- **Mapowanie $C \rightarrow T$ na metylację** metodą *histogram matching* – nieliniowe dopasowanie histogramu wskaźników $C \rightarrow T$ do referencyjnego histogramu metylacji we współczesnej kości człowieka (WGBS).
- **Adaptacyjny rozmiar okna** – do 31 kolejnych CpG, dobierany w zależności od efektywnego pokrycia kohorty.
- **Próg jakości** – do wiarygodnej rekonstrukcji potrzebne jest efektywne pokrycie ≥ 12 (najlepiej > 15). Efektywne pokrycie kohorty można z góry oszacować modelem liniowym z liczby osobników i średniej liczby trafień w autosomalne SNP (*single-nucleotide polymorphism*).

Panel 1240K nie jest połączenie dwóch wcześniejszych paneli wzbogacania opracowanych w laboratorium Davida Reicha (Harvard) we współpracy z grupą Nicka Pattersona i innymi. Stąd bywa nazywany „Reich panel”. Jest używany, ponieważ w kopalnych kościach/zębach DNA endogenne (ludzkie) to często $< 1\%$ całego materiału, pozostała część to bakterie glebowe, grzyby, zanieczyszczenia.

Walidacja wykazała, że zrekonstruowane mapy populacyjne odtwarzają oczekiwane cechy biologiczne: hipometylację wysp CpG i promotorów genów *housekeeping*, wysoką metylację elementów Alu, a także najsilniejszą korelację z metylomem osteoblastów (zgodnie ze szkieletowym pochodzeniem aDNA). Detekcję DMR między populacjami przeprowadza się z kontrolą odsetka fałszywych odkryć (FDR – *false discovery rate*) poprzez permutacje etykiet populacyjnych.

1.1.3.1.4 Narzędzia obliczeniowe

Podejście łączenia [4] jest dla nas kluczowe: umożliwia uzyskanie populacyjnych map metylacji z tysięcy już dostępnych, niskopokryciowych próbek 1240K – w tym z populacji bezpośrednio związanych z przejściem HG $\rightarrow$ AGR (np. brytyjski neolit i epoka brązu, kultura pucharów dzwonowatych). Pozwala to prowadzić porównania HG vs. AGR na poziomie populacji, mimo że pojedyncze próbki są zbyt płytkie do klasycznej rekonstrukcji metylomu. Do zautomatyzowanego przetwarzania wykorzystuje się potoki takie jak epiPALEOMIX [5] oraz RoAM [6].

1.1.3.1.5 Cechy epigenetyczne w ludnościach autochtonicznych

#TODO przepisać i przenieść bibliografie Aktualnie wykazano, że istnieje istotna różnica pomiędzy metylacją w populacjach HG i AGR oraz scharakteryzowano, że jest to związane z regulacją immunologiczną oraz rozwojem [1]. Badania jednak były wykonane na komórkach krwi.

1.1.3.1.6 Analizy wykorzystujące metylacje

Aktualnie wykorzystano metylację do scharakteryzowania różnic w mapach metylacyjnych u Neandertalczyków oraz Denisovian [3] oraz zidentyfikowano ERLs związane z głodem i stwierdzono, że w populacjach HG występowały trendy zmian o charakterze adaptacyjnym [7]. Nie zidentyfikowano jednak charakterystycznych czynników epigenetycznych różnicujących grupy HG i AGR na poziomie tkanki kostnej.

1.2 Metodologia

1.2.1 Kohorty i liczba próbek

Szczegółowy podział kohort referencyjnych i walidacyjnych znajduje się w dedykowanym [arkuszu danych](#).

1.2.2 Mapy metylacyjne

1.2.2.1 Wstęp

Celem tej części metodologii jest odtworzenie populacyjnych map metylacji dla kopalnych kohort walidacyjnych o jednoznacznym trybie życia (pewne HG oraz pewne AGR), a następnie dla populacji niejednoznacznych (np. Çatalhöyük). Mapy te dostarczają wartości m^j wykorzystywanych później w teście klasyfikacyjnym. Ponieważ pojedyncze próbki 1240K mają zbyt niskie pokrycie do rekonstrukcji indywidualnej, mapy budujemy na poziomie populacji, łącząc odczyty wielu osobników z tej samej kohorty. Mapy posłużą potem do walidacji metody.

Choć Çatalhöyük jest zwykle klasyfikowane jako osiedle rolnicze (AGR), jest przejściowe / niejednoznaczne pod względem strategii bytowania.

1.2.2.2 Procedura

Proces przetwarzania danych obejmuje ekstrakcję sygnału deaminacji, filtrowanie artefaktów, nieliniowe dopasowanie histogramów oraz wygładzanie sygnału metodą okien przesuwnych zgodnie z podejściem zaimplementowanym w pakietach referencyjnych [4], [6].

1.2.3 Analiza DMS

1.2.3.1 Wstęp

Dotychczasowa charakterystyka różnic epigenetycznych między populacjami łowiecko-zbierackimi (HG) a rolniczymi (AGR) opiera się przede wszystkim na analizie jednej pary populacji z jednego regionu — afrykańskich łowców-zbieraczy lasu deszczowego oraz sąsiadujących z nimi rolników [1]. Oparcie referencyjnych sygnałów metylacji na pojedynczej parze populacji wiąże się z dwoma istotnymi ograniczeniami.

Po pierwsze, mała liczba niezależnych populacji ogranicza moc statystyczną i wiarygodność identyfikowanych miejsc różnicowo metylowanych (DMS). Po drugie, różnice obserwowane między jedną parą

HG/AGR mogą być zaburzone przez pochodzenie genetyczne, lokalną historię demograficzną oraz specyfikę środowiska, w tym klimat lasu równikowego. W takim układzie trudno rozstrzygnąć, czy wykryty sygnał odzwierciedla rzeczywisty efekt trybu życia, czy raczej lokalną różnicę typu „populacja A vs. populacja B”.

Rozwiązaniem tego problemu jest włączenie wielu niezależnych par HG/AGR pochodzących z różnych kontynentów i stref klimatycznych. Sygnatury epigenetyczne powtarzalne w wielu takich porównaniach z dużo większym prawdopodobieństwem będą odzwierciedlały uniwersalny komponent związany z trybem życia, a nie lokalne uwarunkowania genetyczne, demograficzne lub środowiskowe.

#TODO_6 - Marcin - pewnie będą potrzebne jeszcze propozycje konkretnych populacji tutaj.

1.2.3.2 Procedura

1.2.3.2.1 Metodologia do DNA z populacji dzisiejszych

1. Pozyskanie próbek

- **Tkanka:** krew obwodowa (DNA z leukocytów) — standard w badaniach metylacji populacyjnej i źródło danych referencyjnych [1]. Uwaga: aDNA rekonstruujemy z kości — różnicę tkankową trzeba korygować.
- **Liczebność:** dążyć do $\geq \sim 50$ –100 osób na populację (rzęd wielkości jak w literaturze), zbalansowane między parą HG/AGR.
- **Kryteria włączenia:** dorośli, znany wiek i płeć, brak bliskiego pokrewieństwa, bez ostrej infekcji w chwili poboru.
- **Etyka:** świadoma zgoda i zasady suwerenności danych społeczności (CARE/OCAP) — warunek konieczny.
- **Metadane:** wiek, płeć, region, dieta/tryb życia — potrzebne jako współzmiennie w modelu DMS.

2. Ekstrakcja i kontrola jakości DNA

- Izolacja genomowego DNA standardowym protokołem (np. kolumnienki krzemionkowe).
- Kontrola ilości (fluorymetria, np. Qubit) i integralności (elektroforeza); minimalny wkład zwykle ≥ 250 –500 ng na próbkę.

3. Konwersja dwusiarczynowa (bisulfite conversion)

- Kluczowy krok kodujący metylację chemicznie, przed odczytem na macierzy:
 - niemetylowana cytozyna $\rightarrow$ uracyl $\rightarrow$ (po PCR) tymina,
 - metylowana 5mC pozostaje cytozyną.
- Dzięki temu stan metylacji zamienia się w różnicę sekwencji C/T, którą odczytuje mikromacierz. Stosować zestaw o wysokiej wydajności konwersji ($\geq \sim 99\%$); zalecane powtórzenia techniczne do oceny powtarzalności.

#TODO - Paulina - dopisanie dokładne metodologii do konca (metodologia tych badań które były wykorzystane do autochtonów afrykańskich)z #TODO - Paulina to można rozibć na pojedyncze fragmenty:

1.2.3.2.2 Konwersja dwusiarczynowa (Bisulfite Conversion)

Chemiczne znakowanie stanu metylacji przed analizą mikromacierzową realizowane jest poprzez konwersję w oparciu o następujący schemat reakcji: - Niemetylowana cytozyna (*C*) ulega deaminacji do uracylu (*U*), a następnie podczas matrycowej reakcji PCR ulega substytucji w tyminę (*T*). - Metylowana cytozyna (5mC) pozostaje odporna na działanie wodorosiarczynu, zachowując swoją tożsamość jako cytozyna (*C*).

Wydajność konwersji chemicznej musi wynosić > 99%. W celu empirycznej weryfikacji powtarzalności technicznej procedury stosuje się replikaty techniczne.

1.2.3.2.3 Analiza danych o metylacji DNA

Próbki należy poddać hybrydyzacji przy użyciu mikromacierzy HumanMethylation450, dla próbek i powtórzeń technicznych. Następnie wyeliminować sondy, które mogą ulec hybrydyzacji krzyżowej, te znajdujące się na chromosomach X i Y oraz sondy zawierające SNP lub powiązane z CpG zawierającymi SNP, których częstotliwość przekracza 1% w co najmniej jednej z badanych populacji. Po tym procesie filtrowania poziom metylacji można obliczyć na podstawie surowych danych, korzystając na przykład z pakietu R Bioconductor `lumi`. Należy wybrać, czy lepiej nadać wartość *M*, czy *beta*, sprawdzając, która z nich da lepszą czułość ?. Wybraną wartość należy skorygować pod kątem tła i odchylenia za pomocą np. `lumi` i znormalizować kwantylowo. Różnice techniczne można skorygować normalizując wybraną wartość w ramach macierzy przy użyciu podzbiorów kwantylowych za pomocą pakietu R Bioconductor `minfi`. Analizę PCA można wykryć batch-effect, do skorygowania czego można wykorzystać funkcję `ComBat` z pakietu `sva` bioconductor.

1.2.3.2.4 Określenie miejsc o zróżnicowanym stopniu metylacji - DMS

Określenie tych miejsc między populacjami należy zmodyfikować statystycznie poprzez dopasowanie modelu regresji liniowej dla każdego miejsca (wartości *M*: populacja x płeć x wiek x proporcje typów komórek x błąd) oraz zastosować wygładzenie empiryczne Bayesa do odchylenia standardowego przy użyciu np. pakietu `limma` w bibliotece R bioconductor. Miejsca o skorygowanej wartości *P* poniżej 0,01 według Benjamini i Hochberga uznaje się za różnicowo metylowane. Aby zdefiniować amplitudę DMS, stosuje się różne kryteria: skorygowaną wartość *P* poniżej 0,01 według Benjamini i Hochberga oraz różnicę w średnim poziomie metylacji między dwiema populacjami wynoszącą ponad 2, 5 lub 10%. W tego typu analizie poziom metylacji określa się jako stosunek intensywności sygnału z sondy metylowanej do intensywności ogólnej, czyli wartość *beta*. Należy wyodrębnić nakładające się fragmenty między różnymi zestawami DMS i obliczyć wartości *P* mierzące prawdopodobieństwo uzyskania tych nakładających się fragmentów przez przypadek, stosując ponowne próbkowanie. Poziomy metylacji DNA in docelowych miejscach są silnie skorelowane w obrębie regionów *n* o określonej wielkości (około 2000 pz). W związku z tym dla każdej listy DMS losowo pobiera się ponownie taką samą liczbę miejsc spośród wszystkich miejsc, biorąc pod uwagę odległość między DMS.

1.2.3.2.5 Funkcje biologiczne genów o zróżnicowanym stopniu metylacji

Należy wyodrębnić wszystkie geny o zróżnicowanym stopniu metylacji, czyli geny posiadające co najmniej jeden DMS. Do tego celu można wykorzystać pakiet `goseq` z biblioteki R Bioconductor do przeprowadzenia analizy nadreprezentacji kategorii ontologii genów wśród genów o zróżnicowanym stopniu metylacji. Liczbę sond odpowiadających jednemu genowi wprowadza się do funkcji ważenia prawdopodobieństwa pakietu `goseq`. Ponieważ nie wszystkie geny genomu są reprezentowane na chipie Illumina HumanMethylation450 BeadChip, zestaw referencyjny w analizie nadreprezentacji będzie składał się z genów, dla których dostępne są dane. Zbiory DMS będą istotnie wzbogacone w danej kategorii, jeśli wartość P skorygowana o FDR wyniesie maksymalnie 0,05.

1.2.4 Metoda statystyczna do porównywania populacji.

1.2.4.1 Oznaczenia

Niech K oznacza liczbę zidentyfikowanych DMS.

Dla każdego locus $j \in \{1, \dots, K\}$ wyznaczamy referencyjne częstości metylacji na podstawie wyników z analizy DMS dla populacji łowców ($p_j^{\text{HG}} \in [0, 1]$) oraz rolników ($p_j^{\text{AGR}} \in [0, 1]$).

Dla badanej nieznanej populacji kopalnej X w wyniku map metylacyjnych otrzymujemy poziom metylacji dla każdego locus j , oznaczany jako $\hat{m}_j \in [0, 1]$.

1.2.4.2 Test klasyfikacyjny

Test klasyfikacyjny ma za zadanie sprawdzić, czy dana populacja jest istotnie podobna do populacji agrarnej (AGR) lub tradycyjnej grupy łowiecko-zbierackiej (HG).

Statystykę testową D_{EPM} (Weighted Epigenetic Profile Matching Statistic) definiujemy jako:

$$D_{\text{EPM}}(X) = \sum_{j=1}^K w_j \left[(\hat{m}_j - p_j^{\text{AGR}})^2 - (\hat{m}_j - p_j^{\text{HG}})^2 \right]$$

Gdzie: - $w_j = |p_j^{\text{HG}} - p_j^{\text{AGR}}|$ mówi o tym, jak dany locus jest informatywny. - $D(X) < 0$ jest klasyfikowana jako populacja łowców. - $D(X) > 0$ jest klasyfikowana jako populacja rolników.

Żeby sprawdzić istotność tej zmiany, definiujemy następujące hipotezy: - H_0 : profil metylacji nie wykazuje specyficznego ukierunkowania. - H_1 : profil metylacji wskazuje istotne podobieństwo do jednej z grup.

Oraz stosujemy testy permutacyjne względem wartości $\hat{m}_j$.

1.2.4.3 Testy profilowe

Testy profilowe mają za zadanie identyfikację, czy istotnie występuje metylacja regionów (zbioru DMS) o określonym znaczeniu biologicznym. Regiony te będziemy nazywać grupami funkcjonalnymi, jest to podzbiór zidentyfikowanych loci. Niech $\mathcal{G}$ oznacza zbiór grup funkcjonalnych.

Dla każdej grupy $G \in \mathcal{G}$ definiujemy statystykę testową Λ_G jako:

$$\Lambda_G(X) = \frac{\sum_{j \in G} (\hat{m}_j - p_j^{\text{AGR}})^2 - \sum_{j \in G} (\hat{m}_j - p_j^{\text{HG}})^2}{\sum_{j \in G} (p_j^{\text{HG}} - p_j^{\text{AGR}})^2} \in [-1, 1]$$

Gdzie skala opisuje bliskość względem populacji łowców i populacji rolników.

Żeby sprawdzić istotność każdej z tych zmian, definiujemy następujące hipotezy: - H_0^G : profil metylacji grupy funkcjonalnej G nie wykazuje specyficznego ukierunkowania. - H_1^G : profil metylacji grupy funkcjonalnej G wskazuje istotne podobieństwo do jednej z grup.

Oraz stosujemy testy permutacyjne względem zbioru G , biorąc losowe DMS.

1.3 Oczekiwane wyniki

1.3.1 Cechy charakterystyczne

#TODO - Paulina - jakich cech możemy się spodziewać - sprawdzić czy są zrobione badania na kościach i czy coś z nich wychodzi, czy są jakieś sugestie (ten artykuł o neandertalczyku i denisovian bo oni z człowiekiem całość porównują)

Jeszcze do potwierdzenia i coś do dodania (też z tego artykułu), ale to co wcześniej już pisałam:

- **Recent DMS:** immune regulation (*NFIL3*, *IRF1* and *GATA3*), and fatty acid storage and glucose metabolism (*HNF1A*, *RORA* and *NR1H2::RXRA*)
- ***SOX9*** (5.02×10^{-12} , fold change: 1.48, FDR: 0.052): skeletal development; chondrocyte differentiation — mogą być zmetylowane w przypadku niedożywienia i guess
- ***MEF2A*** (3.95×10^{-7} , fold change: 1.37, FDR: 0.054): activation of growth factor-induced genes; activation of stress-induced genes; skeletal and cardiac muscle development; neuronal differentiation and survival; cell growth and survival; apoptosis
- ***RUNX1*** (1.40×10^{-3} , fold change: 1.27, FDR: 0.055): hematopoiesis; T-cell gene expression regulation
- **Historical:** (they did this)
 - ***TFAP2A*** (1.95×10^{-6} , fold change: 1.42, FDR: 0.062): kidney, eye, face, body wall, limb and neural tube development; early morphogenesis of the lens vesicle

- **NHLH1** (1.55×10^{-3} , fold change: 1.32, FDR: 0.064): cell differentiation; central nervous system development
- **DOCK1 / DOCK3**: rozwój i przebudowa tkanek, wzrost
- **HOXC6**: rozwój szkieletu

1.3.2 Wpływ na tezy historyczne

W przypadku znalezienia charakterystycznych różnic, będzie trzeba znacząco przeformułować niektóre tezy, w szczególności zmienić datowanie opisujące przejście pomiędzy okresem HG i AGR w okresie mezolitu, ponieważ metoda pozwoli nam na dokładniejsze określenie zmian.

1.3.3 Możliwe problemy

1.3.3.1 Znaczące różnice w epigenomach pomiędzy współczesnymi ludnościami autochtonicznymi oraz ludnością prehistoryczną

Może dojść do sytuacji, że różnice w DMS pomiędzy współczesnymi ludnościami autochtonicznymi i prehistorycznymi są na tyle duże, że nie znajdziemy żadnego przecięcia. Może to wynikać nie tylko z znaczących różnic środowiskowych, ale także z ewentualnych zanieczyszczeń. Trzeba by wtedy lepiej dobrać populację testową.

1.3.3.2 Różnice tkankowe między materiałem referencyjnym a kopalnym

Pierwszym istotnym problemem jest różnica tkankowa między materiałem referencyjnym a kopalnym. DMS (*differentially methylated site*) identyfikowane we współczesnej krwi byłyby następnie walidowane na DNA pozyskanym z kości, podczas gdy wzorce metylacji są silnie zależne od typu tkanki. Aby ograniczyć to ryzyko, analizę należy zawęzić do pozycji względnie stabilnych międzytkankowo, w tym potencjalnie do metastabilnych epialleli.

1.3.3.3 Reprezentatywność współczesnych populacji autochtonicznych

Drugie ograniczenie dotyczy reprezentatywności współczesnych populacji autochtonicznych jako modeli populacji prehistorycznych. Dzisiejsze grupy określane jako HG często przeszły kontakt kulturowy, zmiany diety, presję demograficzną oraz ekspozycje środowiskowe odmienne od tych, które charakteryzowały populacje pradziejowe. W konsekwencji nie mogą być traktowane jako wierne odpowiedniki dawnych łowców-zbieraczy, lecz jedynie jako przybliżone populacje referencyjne.

1.3.3.4 Czynniki konfundujące

Trzecim ryzykiem są konfundery związane z pochodzeniem genetycznym, klimatem, środowiskiem lokalnym oraz efektami technicznymi, takimi jak partia eksperymentalna. Sygnał interpretowany jako „HG vs. AGR” może w rzeczywistości odzwierciedlać strukturę populacyjną, lokalną historię demograficzną albo specyficzne warunki środowiskowe. Mitygacja tego problemu wymaga kontroli współzmiennych, uwzględnienia *cis*-meQTL oraz replikacji w wielu niezależnych parach populacji HG/AGR z różnych regionów geograficznych. (Inna genetyka populacji, a nie tylko epigenetyka)

1.3.3.5 Specyfika starożytnego DNA (aDNA)

Czwarta grupa ograniczeń wynika ze specyfiki starożytnego DNA. Deaminacja cytozyn, niskie pokrycie oraz fragmentacja cząsteczek mogą prowadzić do błędnej estymacji proporcji $C \rightarrow T$, a tym samym do fałszywie dodatnich DMR. Minimalnym zabezpieczeniem powinno być zastosowanie progu efektywnego pokrycia, na przykład ≥ 12 , wygładzanie sygnału w oknach genomowych oraz kontrola FDR oparta na permutacjach.

1.3.3.6 Kontaminacja współczesnym DNA

Kolejnym problemem jest kontaminacja współczesnym DNA, która może zaniżać lub zniekształcać rekonstruowany sygnał metylacji. Konieczna jest zatem walidacja profilu uszkodzeń, na przykład z użyciem *mapDamage*, oraz zastosowanie filtrów kontaminacji dostosowanych do typu materiału i jakości biblioteki.

1.3.3.7 Specyficzność typów komórek

Należy także uwzględnić specyficzność typów komórek. W przypadku krwi proporcje komórek immunologicznych silnie wpływają na profil metylacji, natomiast w kości sygnał może zależeć od składu komórkowego tkanki i stopnia remodelingu. Bez korekty składu komórkowego istnieje ryzyko, że wykryte różnice będą odzwierciedlały zmienność tkankową, a nie tryb życia.

1.3.3.8 Wymienność etykiet w testach permutacyjnych

Dodatkowym problemem jest wymienność etykiet w testach permutacyjnych. Jeżeli osobnicy różnią się nie tylko trybem życia, lecz także pochodzeniem, wiekiem próbki, regionem lub jakością zachowania DNA, losowe permutowanie etykiet HG/AGR może prowadzić do obciążonych wartości p . Permutacje powinny być zatem wykonywane w ramach bloków kontrolujących strukturę danych, na przykład region, okres chronologiczny, partię eksperymentalną lub poziom pokrycia.

1.3.3.9 Brak niezależnego złotego standardu (Ryzyko cyrkularności)

Wreszcie, metoda nie dysponuje niezależnym złotym standardem. Status HG/AGR populacji kopalnych pochodzi z interpretation archeologicznej, czyli z tego samego typu informacji, który metoda miałaby częściowo uzupełniać lub weryfikować. Rodzi to ryzyko cyrkularności. Dlatego klasyfikacja epigenetyczna powinna być traktowana nie jako samodzielny dowód trybu życia, lecz jako dodatkowa warstwa informacji integrowana z archeologią, izotopami stabilnymi, paleogenomiką oraz kontekstem środowiskowym.

- [1] M. Fagny and et al., “The epigenomic landscape of african rainforest hunter-gatherers and farmers,” *Nature Communications*, vol. 6, p. 10047, 2015, doi: [10.1038/ncomms10047](https://doi.org/10.1038/ncomms10047).
- [2] A. W. Briggs and et al., “Removal of deaminated cytosines and detection of in vivo methylation in ancient DNA,” *Nucleic Acids Research*, vol. 38, no. 6, p. e87, 2010, doi: [10.1093/nar/gkp1163](https://doi.org/10.1093/nar/gkp1163).
- [3] D. Gokhman and et al., “Reconstructing the DNA methylation maps of the neandertal and the denisovan,” *Science*, vol. 344, no. 6183, pp. 523–527, 2014, doi: [10.1126/science.1250368](https://doi.org/10.1126/science.1250368).
- [4] A. Barouch and et al., “Reconstructing DNA methylation maps of ancient populations,” *Nucleic Acids Research*, vol. 52, no. 4, pp. 1602–1612, 2024, doi: [10.1093/nar/gkae010](https://doi.org/10.1093/nar/gkae010).
- [5] K. Hanghøj and et al., “Fast, accurate and automatic ancient nucleosome and methylation maps with epiPALEOMIX,” *Molecular Biology and Evolution*, vol. 33, no. 13, pp. 3284–3298, 2016, doi: [10.1093/molbev/msw183](https://doi.org/10.1093/molbev/msw183).
- [6] Y. Mathov and et al., “RoAM: A software package for the reconstruction of ancient methylomes.” Software Repository, 2025.
- [7] Anonymous, “Inferring past environments from ancient epigenomes,” *BioRxiv*, 2017.